Tối ưu hóa điều khiển đèn tín hiệu giao thông dựa trên Mô hình Quyết định Markov

Nguyễn Quang Việt – MSSV: 22001659

Phùng Hữu Uy – MSSV: 22001654

Nội dung trình bày

1. Đặt vấn đề và Mục tiêu nghiên cứu
2. Quá trình Quyết định Markov (MDP)
3. Lý thuyết về Học tăng cường (Reinforcement Learning)
4. Deep Q-Network (DQN) & Các cơ chế nâng cao
5. Kết quả thực nghiệm

PHẦN 1

Đặt vấn đề và Mục tiêu nghiên cứu

Bài toán điều khiển đèn giao thông

- **Bối cảnh:** Ùn tắc giao thông đô thị ngày càng nghiêm trọng tại Hà Nội và TP.HCM, gây thiệt hại kinh tế hàng tỷ đồng mỗi ngày.
- **Đặc thù giao thông Việt Nam:**
  - Xe máy chiếm ≈60–70% tổng lưu lượng — cao hơn nhiều so với các nước phát triển
  - Hệ số PCU: 1 ô tô ≈ 3 xe máy về chiếm dụng diện tích
  - Lưu lượng bất đối xứng giữa các trục đường (ví dụ: Đông–Tây gấp đôi Bắc–Nam)
- **Hạn chế phương pháp truyền thống:**
  - Điều khiển thời gian cố định (Fixed-Time): chu kỳ cứng nhắc, không thích ứng
  - Không phản ứng với biến động lưu lượng thực tế
  - Hầu hết nghiên cứu hiện có xây dựng cho giao thông Châu Âu/Bắc Mỹ
- **Mục tiêu điều khiển:** Phân bổ thời gian xanh và chuyển pha tối ưu nhằm giảm ùn tắc, thích ứng theo lưu lượng thực tế.

Giao thông như một bài toán ra quyết định tuần tự

- **Định nghĩa:** Điều khiển đèn giao thông diễn ra theo chuỗi thời gian, quyết định hiện tại ảnh hưởng đến trạng thái tương lai.
- **Đặc điểm:**
  - **Sự đánh đổi:** Ưu tiên một hướng có thể gây ùn tắc ở hướng khác.
  - **Tính động:** Hệ thống tiến triển liên tục; trạng thái kế tiếp phụ thuộc trạng thái hiện tại và hành động đã thực hiện.
  - **Tính ngẫu nhiên:** Phương tiện đến ngẫu nhiên, không thể dự đoán chính xác.
- **Yêu cầu:** Cần một khung mô hình hóa được sự tiến triển trạng thái và tác động dài hạn của quyết định.
- **Hướng tiếp cận:** Mô hình hóa bài toán dưới dạng **MDP** và áp dụng **Deep Reinforcement Learning (Double DQN)** để học chính sách điều khiển tối ưu.

Mục tiêu dự án

1. **Xây dựng môi trường mô phỏng** ngã tư Hà Nội mẫu bằng **SUMO** — tích hợp phân bố xe đặc trưng VN (60% xe máy) và hệ số PCU chuẩn hóa.
2. **Mô hình hóa bài toán** dưới dạng Mô hình Quyết định Markov (MDP): xác định không gian trạng thái (32 chiều), không gian hành động (4 pha đèn) và hàm phần thưởng phản ánh mức độ ùn tắc.
3. **Triển khai thuật toán Double DQN kết hợp Dueling Network** để huấn luyện agent tự thích ứng với biến động giao thông theo thời gian thực.
4. **Đánh giá định lượng** DQN agent so với baseline Fixed-Time 160s qua các chỉ số: hàng đợi, thời gian chờ, tốc độ lưu thông và lưu lượng xe qua nút.

PHẦN 2

Quá trình Quyết định Markov (MDP)

Quá trình Quyết định Markov (MDP) (1)

- **Định nghĩa:** MDP là khung toán học cho việc ra quyết định trong môi trường ngẫu nhiên.
- **Thành phần của MDP:**
  - S: Không gian trạng thái
  - A: Không gian hành động
  - $P(s'|s,a)$: Hàm xác suất chuyển trạng thái — xác suất chuyển từ trạng thái s sang s' sau khi thực hiện hành động a.
  - $R(s,a)$: Hàm phần thưởng — đánh giá mức độ hiệu quả của hành động a tại trạng thái s.
- **Tính chất Markov:**

$$P(s_{t+1}|s_t, a_t) = P(s_{t+1}|s_0, a_0, \ldots, s_t, a_t)$$

Trạng thái tương lai **chỉ phụ thuộc** vào trạng thái hiện tại, không phụ thuộc lịch sử trước đó.

Quá trình Quyết định Markov (MDP) (2)

- **Mục tiêu:** Tìm ra chính sách tối ưu $\pi^*(a|s)$ ánh xạ trạng thái sang hành động nhằm tối đa hóa phần thưởng chiết khấu lũy kế kỳ vọng:

$$\pi^* = \arg\max_{\pi} \mathbb{E}\left[\sum_{t=0}^{\infty} \gamma^t R(s_t, a_t)\right]$$

- Trong đó $\gamma \in (0, 1]$ là **hệ số chiết khấu** — đại diện cho tầm quan trọng tương đối của phần thưởng tương lai so với phần thưởng tức thì.
- Dự án sử dụng $\gamma = 0.99$ — ưu tiên tối ưu hóa dài hạn trong suốt 1 giờ mô phỏng.

Ánh xạ bài toán đèn giao thông sang MDP (1)

- **Tác nhân (Agent):** Hệ thống điều khiển tín hiệu giao thông (DQN agent)
- **Môi trường:** Ngã tư 4 hướng được mô phỏng bởi **SUMO**, giao tiếp qua **TraCI API**
- **Trạng thái (s):** Vector liên tục thu thập từ 8 làn xe vào nút
  - Mỗi làn được biểu diễn bởi **4 đặc trưng**:
    - Số xe dừng — queue length (q_i)
    - Tốc độ trung bình — average speed (v_i)
    - Thời gian chờ tích lũy — waiting time (w_i)
    - Số xe quy đổi PCU — weighted vehicle count (c_i)
  - 4 hướng $\times$ 2 làn/hướng $\times$ 4 đặc trưng $= s \in \mathbb{R}^{32}$
  - **Hệ số PCU Việt Nam:** xe máy (0.5), ô tô (1.5), xe buýt/tải (2.0)
  - q_i, w_i, c_i được nhân thêm **direction weight** theo hướng xe để agent ưu tiên hướng có lưu lượng lớn hơn

Ánh xạ bài toán đèn giao thông sang MDP (2)

- **Không gian hành động (A):** 4 pha tín hiệu được định nghĩa trước
  - a_0 (Pha 0): Bắc – Nam **xanh** — cho phép xe từ hướng Bắc/Nam
  - a_1 (Pha 1): Bắc – Nam **vàng** — pha giải phóng trước khi chuyển sang Đông/Tây
  - a_2 (Pha 2): Đông – Tây **xanh** — cho phép xe từ hướng Đông/Tây
  - a_3 (Pha 3): Đông – Tây **vàng** — pha giải phóng trước khi chuyển sang Bắc/Nam
- Agent ra quyết định mỗi **5 giây** mô phỏng (`action_duration = 5s`)
- Kịch bản lưu lượng bất đối xứng: **Đông–Tây : Bắc–Nam = 2:1**
  EW xanh tối thiểu giữ 60s; NS xanh tối thiểu giữ 30s

Ràng buộc Thời gian Pha (Per-Phase Constraint)

- **Vấn đề:** Nếu agent chuyển pha tùy ý, có thể gây hỗn loạn:
  - Pha xanh chỉ kéo 5 giây $\rightarrow$ phương tiện vừa vào giao lộ không kịp qua
  - Không ổn định trong quá trình học $\rightarrow$ reward dao động lớn
- **Giải pháp:** Ràng buộc riêng biệt cho từng pha xanh:
  - **Pha 2 — EW xanh (trục chính):** $t_{\min} = 60\text{s}$, $t_{\max} = 140\text{s}$
  - **Pha 0 — NS xanh (trục phụ):** $t_{\min} = 30\text{s}$, $t_{\max} = 70\text{s}$
- **Cơ chế thi hành:**
  - Chuyển pha trước $t_{\min}$: **bác bỏ hành động** + phạt reward -1.0
  - Giữ pha vượt $t_{\max}$: **bắt buộc chuyển** sang pha kế tiếp
- **Hiệu ứng bất đối xứng có chủ ý:** EW có $t_{\min}$ gấp đôi NS $\rightarrow$ agent tự nhiên học ưu tiên trục chính, phù hợp tỉ lệ lưu lượng 2:1.

Ánh xạ bài toán đèn giao thông sang MDP (3)

- **Hàm Phần Thưởng Dạng Phạt (R):**
  - Phần thưởng được tính dựa trên mức phạt từ tình trạng ùn tắc hiện tại:

$$R_t = -\left(Q_t + \frac{W_t}{60}\right) + \text{penalty}$$

    - Q_t: tổng số xe dừng (queue) trên tất cả làn, có nhân direction weight
    - W_t: tổng thời gian chờ trên tất cả làn, chia 60 để chuẩn hóa đơn vị
    - penalty $= -1.0$: áp dụng khi agent cố chuyển pha trước $t_{\min}$
  - R_t càng gần 0: giao thông càng thông thoáng
  - R_t càng âm: ùn tắc càng nghiêm trọng
- **Chuyển đổi trạng thái (P):**
  - Phụ thuộc vào hành động a_t (pha đèn được áp dụng)
  - Động lực học phương tiện trong mô phỏng SUMO
  - Sự xuất hiện ngẫu nhiên của xe mới theo phân bố xác suất cố định

PHẦN 3

Lý thuyết về Học tăng cường (Reinforcement Learning)

Học tăng cường là gì?

- Reinforcement Learning (RL) là phương pháp giúp máy tính tự học thông qua quá trình thử và rút kinh nghiệm.
- Ta có thể hiểu đơn giản:
  - Làm đúng $\rightarrow$ được thưởng
  - Làm chưa tốt $\rightarrow$ bị phạt
  - Sau nhiều lần thử, agent sẽ học được cách hành động tốt hơn
- Trong dự án này:
  - Agent đóng vai trò là hệ thống điều khiển đèn giao thông
  - Môi trường là mô phỏng giao thông SUMO
  - Mục tiêu là giảm ùn tắc và giảm thời gian chờ xe
- RL phù hợp với bài toán giao thông vì lưu lượng xe luôn thay đổi theo thời gian thực.

Cách RL hoạt động

Quá trình học của RL diễn ra theo các bước:

1. Agent quan sát tình trạng giao thông hiện tại
2. Agent quyết định đổi hoặc giữ đèn tín hiệu
3. Môi trường cập nhật trạng thái giao thông mới
4. Agent nhận đánh giá tốt hoặc xấu thông qua reward

Ví dụ:

- Nếu giảm được hàng xe chờ $\rightarrow$ reward cao
- Nếu gây ùn tắc nhiều hơn $\rightarrow$ reward thấp

Mục tiêu cuối cùng:

- Học ra cách điều khiển đèn giao thông hiệu quả nhất trong thời gian dài

Khám phá và khai thác

- Trong RL có một vấn đề quan trọng:
  - Khám phá (exploration)
  - Khai thác (exploitation)
- **Khám phá:**
  - Thử các hành động mới để tìm cách tốt hơn
- **Khai thác:**
  - Sử dụng hành động mà agent đã học là hiệu quả nhất
- Dự án sử dụng chiến lược ϵ-greedy:
  - Giai đoạn đầu: agent thử nhiều hành động ngẫu nhiên để học
  - Giai đoạn sau: agent dần ưu tiên các hành động tốt đã học được
- Nhờ vậy hệ thống vừa học được kiến thức mới, vừa tối ưu hiệu quả điều khiển giao thông.

PHẦN 4

Deep Q-Network (DQN) & Các cơ chế nâng cao

Deep Q-Network (DQN)

- DQN sử dụng mạng nơ-ron sâu để ước lượng giá trị hành động:

$$Q(s, a)$$

- Có thể hiểu đơn giản:
  - s: trạng thái giao thông hiện tại
  - a: hành động điều khiển đèn
  - $Q(s, a)$: mức độ "tốt"của hành động đó
- Trong dự án:
  - Input: trạng thái giao thông
  - Output: giá trị cho các hành động điều khiển đèn
- Agent sẽ chọn hành động có giá trị Q cao nhất để giảm ùn tắc và thời gian chờ.

Kiến trúc Dueling DQN

- Dueling DQN chia mạng thành hai phần:
  - **Value** $V(s)$:
    - Đánh giá trạng thái giao thông hiện tại tốt hay xấu
  - **Advantage** $A(s, a)$:
    - Đánh giá hành động nào tốt hơn trong trạng thái đó
- Sau đó kết hợp lại:

$$Q(s, a) = V(s) + A(s, a)$$

- Ý nghĩa:
  - Giúp agent học ổn định hơn
  - Đánh giá giao thông hiệu quả hơn

Experience Replay

- Mỗi trải nghiệm được lưu dưới dạng:

$$(s, a, r, s')$$

- Bao gồm:
  - s: trạng thái hiện tại
  - a: hành động đã chọn
  - r: reward nhận được
  - s': trạng thái tiếp theo
- Agent sẽ lấy ngẫu nhiên các trải nghiệm cũ để học lại.
- Lợi ích:
  - Học ổn định hơn
  - Tận dụng lại kinh nghiệm cũ
  - Giảm việc học bị lệch do dữ liệu liên tiếp

Double DQN

- DQN thông thường đôi khi đánh giá quá cao giá trị hành động.
- Double DQN giải quyết bằng cách:
  - Một mạng dùng để chọn hành động
  - Một mạng dùng để đánh giá hành động
- Công thức chính:

$$a^* = \arg\max_a Q(s', a)$$

- Ý nghĩa:
  - Chọn hành động tốt nhất tại trạng thái tiếp theo
  - Giúp kết quả học chính xác và ổn định hơn

Target Network

- Dự án sử dụng thêm một mạng gọi là target network.
- Mạng này được cập nhật chậm hơn mạng chính:

$$\theta^{-} \leftarrow \theta$$

- Có thể hiểu đơn giản:
  - Một mạng để học
  - Một mạng làm mốc tham chiếu
- Tác dụng:
  - Giúp mô hình học ổn định hơn
  - Tránh thay đổi quá nhanh gây sai lệch

Kiến trúc tổng thể Dueling Double DQN

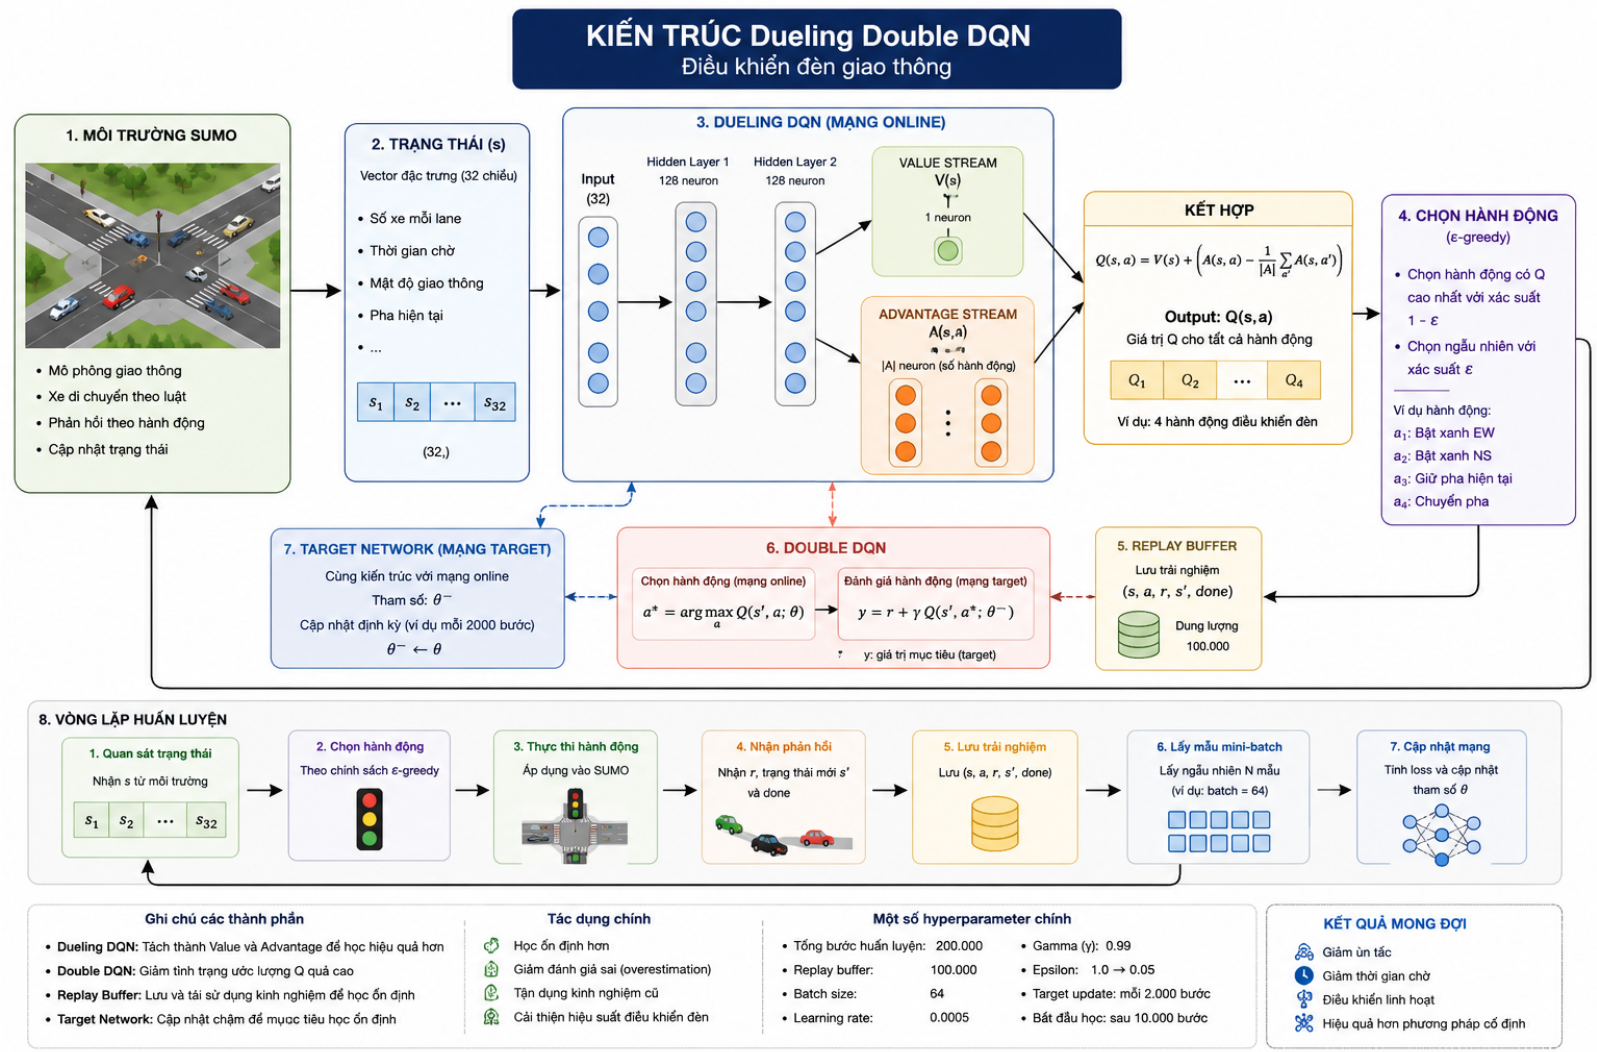

PHẦN 5

Kết quả thực nghiệm

Thiết lập thực nghiệm

Môi trường mô phỏng:

- Kịch bản: Ngã tư 4 hướng, Hà Nội mẫu (SUMO)
- Thời gian mỗi episode: 3600 giây (1 giờ)
- Warmup: 60 giây trước khi agent can thiệp
- Lưu lượng EW:NS = 2:1; 60% xe máy
- GUI: tắt (headless) khi huấn luyện

Baseline so sánh — Fixed-Time 160s:

- EW xanh: 100s → EW vàng: 5s
- NS xanh: 50s → NS vàng: 5s
- Chu kỳ cố định, **không thích ứng**
- Tỉ lệ 2:1 đã được phản ánh trong baseline

5 chỉ số đánh giá chính:

- Độ dài hàng đợi trung bình và cực đại (xe dừng)
- Thời gian chờ trung bình (giây/bước)
- Tốc độ lưu thông trung bình (m/s)
- Lưu lượng xe qua nút / episode (throughput)

Kết quả so sánh DQN vs. Fixed-Time

Chỉ số	DQN	Fixed-Time	Thay đổi	Cải thiện
Hàng đợi TB (xe)	**16.05**	33.13	−17.08	↓51.6%
Hàng đợi Max (xe)	**51**	66	−15	↓22.7%
Độ lệch chuẩn	**8.16**	12.77	−4.61	↓36.1%
Thời gian chờ (s)	**30.55**	121.35	−90.80	↓74.8%
Tốc độ TB (m/s)	**5.65**	4.87	+0.78	↑16.0%
Throughput (xe)	**344**	338	+6	↑1.8%
Total Reward	**−14.754**	−35.512	+20.758	↑58.5%

DQN vượt trội hơn Fixed-Time trên tất cả 7 chỉ số

Phân tích kết quả (1): Hàng đợi và Thời gian chờ

- **Hàng đợi trung bình giảm 51.6%**
  - DQN: 16.05 xe/làn Fixed-Time: 33.13 xe/làn
  - Độ lệch chuẩn thấp hơn 36.1% → DQN **ổn định hơn**, ít đợt ùn tắc đột ngột
- **Thời gian chờ giảm 74.8%** — cải thiện lớn nhất trong tất cả chỉ số
  - DQN: 30.55 s/bước Fixed-Time: 121.35 s/bước
- **Lý do:** Agent học phân bổ pha xanh đúng lúc, đúng hướng:
  - Quan sát q_i, w_i liên tục theo thời gian thực
  - Tập trung thời gian xanh vào hướng đang tích lũy xe
  - Không lãng phí thời gian xanh khi hướng đó vắng xe
- **Fixed-Time không thể làm điều này:** dù NS tắc hay EW trống, đèn vẫn giữ đúng 100s/50s cố định.

Phân tích kết quả (2): Tốc độ, Throughput và Reward

- **Tốc độ lưu thông tăng 16.0%**
  - DQN: 5.65 m/s Fixed-Time: 4.87 m/s
  - DQN không chỉ giảm hàng đợi mà còn giúp xe di chuyển nhanh hơn tổng thể
- **Throughput tăng 1.8%** (344 vs 338 xe/episode)
  - Mức cải thiện khiêm tốn — cả hai chiến lược xử lý lượng xe tương đương
  - Nhưng DQN thực hiện điều này với **ít ùn tắc và thời gian chờ thấp hơn đáng kể**
- **Total Reward cải thiện 58.5%**
  - DQN: -14.754 Fixed-Time: -35.512
  - Reward âm tỉ lệ với mức ùn tắc $\rightarrow$ DQN cao hơn nghĩa là ít ùn tắc hơn
  - Xác nhận agent đã tối ưu hóa thành công hàm mục tiêu đề ra
- **Chiến lược học được:** giữ EW $\geq$ 60s, không bỏ quên NS, tránh penalty -1.0

Kết luận và Hướng phát triển

Kết quả đạt được:

- Mô hình hóa thành công bài toán điều khiển đèn dưới dạng MDP với đặc thù giao thông Việt Nam
- Double DQN + Dueling Network vượt trội hơn Fixed-Time 160s trên tất cả các chỉ số
- Giảm hàng đợi **51.6%**, thời gian chờ **74.8%**, tăng tốc độ **16.0%**

Hướng phát triển:

- **Multi-Agent RL (MARL)**: điều phối đồng thời nhiều nút giao thông
- **Transfer Learning**: tái sử dụng model đã huấn luyện cho kịch bản mới
- **Dữ liệu thực**: tích hợp camera/cảm biến tại nút giao Hà Nội thực tế
- **Reward nâng cao**: bổ sung khí thải, nhiên liệu, mức độ an toàn

Cảm ơn thầy/cô và các bạn đã lắng nghe!